

Trabajo Práctico Integrador: Módulo R

Determinantes del salario en Argentina mediante regresión LASSO y aplicación de Regresión Logit Binomial para clasificación Formal/Informal

Maestría en Econometría - UTDT

Septiembre 2026

Elección del dataset y de las técnicas analíticas

Para este trabajo práctico, seleccionamos los microdatos de la Encuesta Permanente de Hogares (EPH) provistos por el INDEC, específicamente los correspondientes al cuarto trimestre de 2023. El análisis se estructura en torno a dos dimensiones fundamentales del mercado laboral argentino. Por un lado, buscamos responder: ¿Cuáles son los verdaderos determinantes del salario cuando controlamos simultáneamente por múltiples factores sociodemográficos y laborales? Por otro lado, nos preguntamos: ¿Qué características aumentan la probabilidad de que un trabajador se encuentre en situación de informalidad laboral (sin aportes jubilatorios)?


Para abordar la primera interrogante relacionada a la predicción de ingresos, decidimos aplicar la técnica de Regularización LASSO combinada con Validación Cruzada (10-Fold CV). El fundamento de esta decisión radica en que, al intentar expandir la ecuación de Mincer clásica incorporando numerosas variables categóricas (como región o tamaño exacto de la empresa), el modelo lineal por mínimos cuadrados ordinarios (MCO) tradicional sufre problemas de multicolinealidad. LASSO nos permite penalizar la complejidad del modelo, llevando a cero los coeficientes de las variables redundantes y realizando una selección algorítmica y objetiva de los predictores más relevantes.

Para responder a la segunda interrogante, implementamos un modelo de Regresión Logística Binomial (Logit) mediante un Modelo Lineal Generalizado (GLM). La elección de esta técnica se fundamenta en su capacidad matemática para resolver problemas de clasificación binaria. A través de la extracción de *Odds Ratios*, este modelo nos permite interpretar estadísticamente la dirección y magnitud del riesgo de caer en la informalidad según las distintas características del trabajador y su puesto, permitiéndonos además evaluar el rendimiento discriminatorio del modelo mediante herramientas métricas como la Matriz de Confusión y el Área Bajo la Curva ROC (AUC).


Análisis Exploratorio de Datos (EDA)

Filtramos el dataset original para quedarnos exclusivamente con la población objetivo: individuos ocupados, asalariados (descartando cuentapropistas y patrones), de entre 18 y 65 años, y con ingresos positivos en su ocupación principal. Asimismo, eliminamos los valores faltantes de las variables de interés asumiendo un patrón de ausencia completamente aleatorio.

Como la distribución del ingreso laboral en pesos es fuertemente asimétrica y presenta una larga cola hacia la derecha, aplicamos una transformación logarítmica sobre la variable objetivo. Esta transformación normaliza la distribución y nos permite interpretar los coeficientes resultantes en términos porcentuales.




Al explorar la relación bivariada entre educación, género y salario, el análisis visual confirma la teoría del capital humano: la mediana del ingreso escala con cada nivel formativo completado. No obstante, se evidencia una brecha salarial persistente en contra de las mujeres a través de todos los niveles educativos.



Aplicación de la Regularización LASSO e interpretación


Para garantizar una evaluación honesta de nuestro modelo predictivo y evitar el sobreajuste, dividimos la muestra en un conjunto de entrenamiento (70%) y un conjunto de prueba (30%). Construimos una matriz de diseño que se encargó de binarizar automáticamente todas nuestras variables categóricas.

A continuación, visualizamos el error de predicción en función de la fuerza de regularización. La primera línea punteada vertical (leyendo de izquierda a derecha) señala el modelo más parsimonioso ($\lambda=0.0119$), mientras que la segunda línea punteada indica el valor óptimo que minimiza el error cuadrático medio, que selecciona 24 variables, sin descartar ninguna ($\lambda=0.0003$).




Al evaluar el modelo que minimiza el error cuadrático medio sobre los datos no vistos del conjunto de prueba, obtuvimos un RMSE de 0.56 y un R cuadrado fuera de muestra del 42%, representando una gran capacidad predictiva y de generalización.

A continuación, visualizamos el orden de importancia de los factores que sobrevivieron a la penalización del algoritmo (todos), evaluados en el hiperparámetro óptimo.



Cuando evaluamos el modelo mas parsimonioso sobre los datos no vistos se pierde un poco de poder predictivo (el R-cuadrado bajó de casi 42% a 39.86% y el RMSE subió levemente a 0.5709) a costa de un modelo mas simple.

A continuación, visualizamos el orden de importancia de los factores que sobrevivieron a la penalización del algoritmo (todos), evaluados en el hiperparámetro mas parsimonioso.



Si comparamos la nueva lista con la anterior, el algoritmo decidió descartar 3 variables (llevó sus coeficientes a cero absoluto):

exper2 (Experiencia al cuadrado): El algoritmo concluyó que capturar el efecto decreciente (no lineal) de la experiencia no justificaba la complejidad extra, quedándose únicamente con la variable experiencia lineal.

region43: La brecha salarial de esta región específica frente a la región base (GBA) dejó de ser lo suficientemente relevante bajo un castigo más estricto.

tamano_emp7: Este estrato intermedio de tamaño de empresa fue descartado.

A su vez, notamos un reordenamiento de importancia en las variables. En el modelo anterior, trabajar en las empresas más grandes (tamano_emp12) lideraba el impacto salarial. En este modelo, el castigo por trabajar en microempresas (tamano_emp2) y en jornada_compParcial tomó reelevancia en términos de magnitud absoluta, superando la prima salarial de la educación superior (nivel_edSuperior).

Interpretación, Comparación de Modelos y Limitaciones

El análisis empírico confirma la vigencia de la teoría del capital humano: la educación superior es un determinante positivo fundamental del salario en Argentina. Simultáneamente, el algoritmo ratifica la persistencia de una brecha salarial negativa para las mujeres, la cual se mantiene robusta incluso tras someter el modelo a penalizaciones algorítmicas y controlar por nivel educativo, jornada y sector.

El hallazgo estructural más destacable es la influencia de la variable tamano_emp. La segmentación del mercado laboral demuestra tener un poder predictivo altísimo en la fijación salarial. El modelo asigna coeficientes fuertemente positivos a las empresas de gran envergadura y penalizaciones significativas a las microempresas, evidenciando que el tamaño de la empresa juega un rol tan o más importante que las certificaciones educativas.

Al contrastar el modelo predictivo óptimo ($\lambda_{\min}$) con la especificación más parsimoniosa (λ_{1se}), emerge un claro trade-off entre precisión y simplicidad. El modelo restringido descarta por completo factores de menor impacto (como el efecto no lineal de la experiencia, *exper2*, y ciertas diferencias regionales) a cambio de una leve caída en el R-cuadrado. Bajo esta regularización más estricta, las penalizaciones absolutas por trabajar a tiempo parcial o en una microempresa pasan a liderar la escala, superando en magnitud a la prima otorgada por la educación universitaria.

Limitaciones del análisis: Si bien la regularización LASSO es una técnica excelente para seleccionar variables y eludir la multicolinealidad, los coeficientes resultantes se encuentran deliberadamente sesgados hacia cero por diseño. Asimismo, estas estimaciones capturan relaciones estrictamente predictivas, no causales. Persisten posibles sesgos por variables omitidas inobservables, tales como la habilidad intrínseca del individuo o la condición de formalidad laboral, un factor crítico que amerita ser analizado bajo modelos de clasificación específicos.

Regresión Logística y Probabilidad de Informalidad

Para complementar el análisis de ingresos, estimamos un modelo de Regresión Logística (Logit) con el objetivo de identificar qué características sociodemográficas y laborales aumentan la probabilidad de que un asalariado trabaje en la informalidad (sin descuentos jubilatorios).

```
##
## --- Top 5 factores que aumentan la CHANCE de informalidad (Odds Ratios > 1) ---

## # A tibble: 5 x 5
##   term                estimate  p.value  conf.low  conf.high
##   <chr>                <dbl>    <dbl>    <dbl>    <dbl>
## 1 jornada_compParcial    2.07 2.73e-13    1.70      2.49
## 2 tamano_emp2           1.98 5.97e- 2    0.959     3.99
## 3 region40              1.85 1.22e- 9    1.52      2.25
## 4 region42              1.79 1.12e- 6    1.42      2.27
## 5 region41              1.43 4.56e- 3    1.12      1.83
```

Al extraer y ordenar los Odds Ratios (exponenciando los coeficientes del modelo), identificamos los factores de mayor riesgo. Trabajar en jornada parcial duplica ($OR = 2.07$) las chances de estar en la informalidad en comparación con una jornada completa. A su vez, residir en el NOA o Cuyo y trabajar en microempresas actúan como fuertes aceleradores de la probabilidad de no estar registrado.

Para evaluar la capacidad predictiva del modelo, calculamos las probabilidades sobre el conjunto de prueba (no visto por el algoritmo) y las convertimos a una clasificación binaria utilizando un umbral de corte de 0.5.


```
##
## --- Matriz de Confusión (Umbral 0.5) ---

##           Real
## Prediccion  0    1
##           0 2159 436
##           1  249 668

##
## Accuracy global: 80.50%
```

La matriz de confusión arroja 2159 Verdaderos Negativos, es decir el modelo predice que el trabajador es formal cuando efectivamente lo es. Esto representa el mayor volumen de aciertos, demostrando que el algoritmo es muy bueno detectando el empleo en blanco. A su vez los Verdaderos Positivos, cuando el modelo predice correctamente que estas personas están en la informalidad, son 668. Por otro lado, 249 veces el modelo etiqueta a personas que tienen un trabajo formal como informales (Falsos Positivos). No obstante, los Falsos Negativos son 436. El algoritmo analiza a estas 436 personas y deduce que, por sus características (educación, tamaño de empresa, etc.), deben tener un trabajo en blanco (0). Sin embargo, en la realidad se encuentran trabajando en la informalidad (1). El sesgo hacia los Falsos Negativos ocurre porque la base de datos está desbalanceada (hay más trabajadores formales que informales en la muestra general), por lo que ante la duda de perfiles ambiguos, el modelo con un corte en 0.5 tiende a apostar por la formalidad.

La precisión global (Accuracy) del modelo fue del 80.50%, esto significa que acierta en 8 de cada 10 casos evaluados sin conocer la respuesta real. Para confirmar la robustez de este poder de clasificación a través de distintos umbrales, calculamos el Área Bajo la Curva ROC (AUC).



Un AUC de 0.844 ratifica que el modelo posee una excelente capacidad discriminatoria, es decir que si seleccionamos al azar a un trabajador formal y a uno informal, el modelo tiene un 84.4% de probabilidad de asignarle el mayor riesgo estadístico a la persona que efectivamente trabaja “en negro”. En términos sustantivos, esto implica que las características observables del puesto (principalmente el tamaño del establecimiento y la jornada) y de la geografía, bastan para predecir con un altísimo grado de certeza el nivel de desprotección laboral del individuo en el mercado argentino.

A su vez, la Curva ROC demuestra visualmente que el modelo logra capturar a la gran mayoría de los informales reales (alta Sensibilidad) sin equivocarse demasiado y etiquetar erróneamente a los formales (alta Especificidad).

Conclusiones Generales

El presente trabajo permitió abordar la complejidad del mercado laboral argentino (EPH, cuarto trimestre de 2023) combinando técnicas de *Machine Learning* para la predicción continua de ingresos y la clasificación binaria de la informalidad.

Por un lado, la aplicación de modelos de regularización LASSO sobre una ecuación de Mincer extendida ratificó los postulados clásicos del capital humano: la educación superior otorga una prima salarial significativa, mientras que las mujeres enfrentan una brecha de ingresos negativa sostenida, incluso controlando por el resto de las variables. Sin embargo, el hallazgo estructural más relevante de esta etapa fue el impacto determinante del tamaño del establecimiento. Al evaluar el modelo más parsimonioso (`lambda.1se`), el algoritmo demostró que la segmentación del mercado es crucial: las penalizaciones por trabajar en microempresas y en jornadas parciales superan en magnitud absoluta a los beneficios de contar con un título universitario. Asimismo, el contraste entre especificaciones evidenció el *trade-off* algorítmico entre retener el máximo poder predictivo (`lambda.min`) o forzar la simplicidad eliminando variables de impacto marginal.

Por otro lado, el abordaje de la informalidad laboral mediante regresión logística (Logit) complementó esta visión al modelar la probabilidad de no contar con aportes jubilatorios. El modelo demostró una excelente capacidad de clasificación estadística, logrando una precisión global (*Accuracy*) del 80.50% y un Área Bajo la Curva (AUC) de 0.844. El análisis de *Odds Ratios* reveló que las vulnerabilidades se acumulan: trabajar en una jornada parcial duplica el riesgo de caer en la informalidad frente a una jornada completa, operando junto con el tamaño de la empresa y la radicación en regiones como el NOA y Cuyo como los principales aceleradores de la desprotección.

En síntesis, la complementariedad de ambas metodologías evidencia una segmentación estructural profunda en la economía argentina. Las mismas características laborales que el algoritmo LASSO identifica como “castigos” en la determinación del salario (tamaño reducido de la empresa, subocupación horaria, rezago regional), son exactamente los mismos factores que el modelo Logit aísla como los vectores de mayor riesgo para caer en la informalidad. Esto demuestra que la desigualdad en el mercado laboral no opera únicamente a través de las credenciales educativas, sino que está fuertemente determinada por la estructura productiva del puesto de trabajo.